732G53 Linjär regression – fusklapp

Notation: n = antal obs., k = antal förklarande variabler (lutningsparametrar), $p = k+1$ = antal parametrar, $df_E = n-(k+1)$. Källor: hietalai.github.io/statistics-in-r (Del II) och tentor 2024-10-25 – 2025-10-23.

1 Hitta rätt avsnitt – vanliga tentafrågor

b_0, b_1, ANOVA, test, KI/PI för hand (enkel regression)	§6 (s.1), §8 (s.1)
Ange/kontrollera antagandena, tolka residualdiagram/QQ-plot	§3 (s.1), §4 (s.1)
Rita/tolka spridningsdiagram, korrelationsmatris	§5 (s.1)
OLS-egenskaper, normalekvationer	§9 (s.2)
Hypotesprövningens steg, p-värde	§10 (s.2)
Tolka koefficient, R^2, intervall	§11 (s.2)
Tolka och testa indikator, interaktion	§20 (s.3), §21 (s.3)
Läs utskrifterna i tentan, R^2 ur ANOVA-tabell, sekventiella SS	§13 (s.2), §19 (s.3)
F-test för modellen / t-test för en parameter	§14 (s.2), §16 (s.2)
Partiellt F: kvalitativ variabel, ”kan modellen reduceras?”	§15 (s.2)
Prediktion (snabbformel med c); flera intervall samtidigt	§17 (s.2), §18 (s.2)
Polynom, transformation, centrering	§22 (s.3)
Leverage, jackknife, DFFITS, Cook’s distance	§23 (s.3)
Korrelationsmatris, VIF, multikollinearitet	§24 (s.3)
Confounding, kontrollvariabel, Simpsons paradox	§25 (s.3)
Välj modell: C_p, AIC(c), PRESS, korsvalidering, algoritmer	§26 (s.3), §27 (s.4)
Är modellen bra/lämplig? Jämför modeller (residualer, R^2_a)	§28 (s.4)
Sant/falskt-påståenden; korta svar på teorifrågor	§29 (s.4), §31 (s.4)
Läsa tabellsamlingen (t, F, z); QQ-kvantiler för hand	§34 (s.4)

2 Vilket verktyg? – fråga → metod → jämför med

Frågan säger	*Använd*	*Jämför med / gräns*
”har X_j en effekt?” (en kvantitativ variabel); ”positiv/negativ effekt” ⇒ ensidigt	$t = b_j/s_{b_j}$ (§16)	$t_{n-p;1-\alpha/2}$; ensidigt $t_{n-p;1-\alpha}$
”testa modellen” / ”är modellen signifikant?”	$F = \text{MSR}/\text{MSE}$ (§14)	$F_{k,n-p;1-\alpha}$
”kan A reduceras till B?”, kvalitativ variabel (c nivåer), ”behövs interaktion/polynom?”	partiellt F (§15)	$F_{s,n-p_F;1-\alpha}$
”genomsnittlig/förväntad”, ”konfidensintervall” – KI även om ”en villa” nämns	**KI** $\hat{y}_0 \pm t s_{\hat{y}_0}$ (§6, §17)	–
”ny/enskild observation”, ”prediktionsintervall”	**PI** $\hat{y}_0 \pm t\sqrt{\text{MSE}+s^2_{\hat{y}_0}}$	ges c: $t\sqrt{\text{MSE}(1+c)}$
”flera parametrar/intervall samtidigt”	Bonferroni B, Working–Hotelling W, Scheffé S (§18) – välj minsta multiplikatorn	
”avvikande i x-led / i y-led / inflytelserik?”	$h_i > 2p/n$; jackknife $\lvert r_{(-i)}\rvert > 2$–3; DFFITS > 1 el. $2\sqrt{p/n}$; Cook > 1 el. A.10-värde/$(n-p)$ (§23)	
”multikollinearitet?”	korrelationsmatris, VIF (§24)	$\lvert r\rvert > 0.9$; VIF > 10; medel-VIF > 5
”bästa modell (olika storlek)?”	R^2_a (hög), $C_p \approx p$, AIC/AICc, PRESS, MSPR, CV (alla låga) (§26)	
”förklaringsgrad ur ANOVA-tabell”	$R^2 = 1 - \text{SSE}/\text{SSY}$, SSY = summan av **alla** SS-rader (§13)	

3 Modell och antaganden

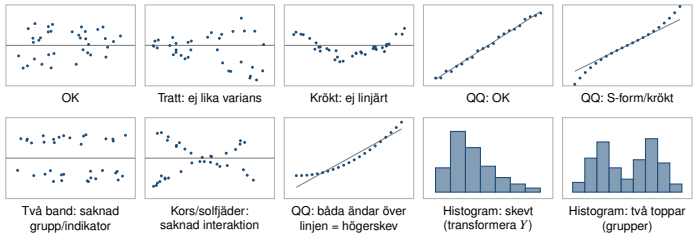
$Y_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_k X_{ik} + E_i$, $E_i \overset{\text{iid}}{\sim} N(0,\sigma^2)$ $\Leftrightarrow$ $Y|X \overset{\text{ind}}{\sim} N(\mu_{Y|X}, \sigma^2)$ med $\mu_{Y|X} = E[Y|X] = \beta_0 + \beta_1 X_1 + \ldots$ (väntevärdet saknar felterm). Skattad modell: $\hat{y}_i = b_0 + b_1 x_{i1} + \cdots + b_k x_{ik}$ ($b_j = \hat{\beta}_j$); residual $e_i = y_i - \hat{y}_i$ skattar E_i. Minsta kvadratmetoden (OLS) väljer b_j som minimerar $\text{SSE} = \sum e_i^2$. **Enkelt:** *linjen är vår bästa gissning av Y när vi vet X; residualen är hur mycket gissningen missade för en punkt. OLS väljer linjen så att summan av alla missar i kvadrat blir minimal.*

Antaganden (1) för varje X finns en slumpvariabel Y med ändliget medelvärde och varians; (2) oberoende observationer; (3) linjäritet: $\mu_{Y|X}$ linjär i parametrarna; (4) lika varians $\sigma^2_{Y|X} \equiv \sigma^2$ (homoskedasticitet); (5) $Y|X$ normalfördelad. **OBS!** Inget antagande om att Y självt är normalfördelat – kontrollera *residualerna*. Kontrollera antagandena *innan* test/intervall tolkas.

Kontroll (✓ = uppfyllt, ✗ = ej uppfyllt)

- **Linjäritet** – e mot $\hat{y}$ (och mot varje X_j). ✓ slumpmässig svärm kring 0 utan mönster. ✗ krökt/U-format mönster (även krökt QQ) ⇒ lägg till X^2, interaktion, saknad variabel eller transformera.
- **Lika varians** – e mot $\hat{y}$. ✓ jämnbrett band: två parallella linjer längs min/max ramar in punkterna. ✗ tratt/kon (spridningen ökar/minskar med $\hat{y}$) ⇒ transformera Y ($\ln Y$, $\sqrt{Y}$).
- **Normalfördelning** – histogram och QQ-plot av residualerna. ✓ symmetrisk klockform kring 0; punkterna följer linjen. ✗ skev, flera toppar (saknad grupperingsvariabel), S-form/tunga svansar, extremvärden.
- **Oberoende** – e mot observationsordning (linjediagram) + hur data samlats in. ✓ inget mönster (”slump”). ✗ trender/vågor: tidsserier, upprepade mätningar på samma enhet, familjer, närliggande platser.

Litet n (t.ex. 6): svårt att bedöma – skriv det. *Formulering:* ”Residualerna ser approximativt normalfördelade ut: histogrammet är symmetriskt och klockformat kring 0 och punkterna i QQ-diagrammet följer linjen. Residualerna mot anpassade värden bildar ett jämnbrett band utan mönster ⇒ linjäritet och lika varians verkar uppfyllda.”



4 Läsa QQ-plot och residualmönster

- **QQ-plot** (observerade mot teoretiska kvantiler): längs linjen ⇒ normalfördelat. Båda ändarna *över* linjen (konvex) ⇒ högerskev; båda *under* (konkav) ⇒ vänsterskev; vänster ände under och höger över (S-form) ⇒ tunga svansar/extremvärden; tvärtom ⇒ lätta svansar; hopp/trappsteg ⇒ grupper. Krökt mönster kan också spegla icke-linjäritet (kurssidan).
- e **mot** $\hat{y}$**:** två eller flera band ⇒ saknad kategorisk variabel (mod_2 i tenta 2025-10-23); kors-/solfjädersmönster ⇒ saknad interaktion; enstaka punkt långt från 0 ⇒ möjligt extremvärde (kontrollera standardiserad/jackknife-residual); punkter långt ut i $\hat{y}$-led (även med liten e) ⇒ möjlig hög leverage – kontrollera h, Cook (§23).

5 Utforskande analys och spridningsdiagram

Rita: förklarande X på x-axeln, respons Y på y-axeln, axeltitlar med enhet, rubrik. **Beskriv fyra saker:** (1) linjärt? (2) positivt/negativt? (3) starkt/svagt? (4) extremvärden? Kvalitativ X: fiol-/lådagram per kategori. Responsens histogram behöver *inte* vara normalfördelat. **Pearsons** r ($-1 \le r \le 1$) mäter bara *linjära* samband – missvisande vid krökta/icke-monotona samband och vid grupper (Simpsons paradox, §25); visualisera alltid. Korrelationsmatris: högt $|r(X_j,Y)|$ ⇒ relevant variabel; högt $|r(X_i,X_j)|$ ⇒ risk för multikollinearitet.

6 Enkel linjär regression – räkna för hand

$$S_{xx} = \sum(x_i-\bar{x})^2 = \sum x_i^2 - (\sum x_i)^2/n$$
$$S_{yy} = \text{SSY} = \sum(y_i-\bar{y})^2 = \sum y_i^2 - (\sum y_i)^2/n$$
$$S_{xy} = \sum(x_i-\bar{x})(y_i-\bar{y}) = \sum x_i y_i - \sum x_i \sum y_i/n$$

$b_1 = \dfrac{S_{xy}}{S_{xx}}$, $b_0 = \bar{y} - b_1\bar{x}$ (linjen går genom $(\bar{x},\bar{y})$; $\sum e_i = 0$, $\sum x_i e_i = 0$)

$\text{SSR} = b_1 S_{xy} = S_{xy}^2/S_{xx}$, $\text{SSE} = S_{yy} - b_1 S_{xy} = \sum(y_i-\hat{y}_i)^2$

$s^2 = \text{MSE} = \text{SSE}/(n-2)$, $s = \sqrt{\text{MSE}}$ (residualspridning)

$r = \dfrac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}$, $R^2 = r^2 = \dfrac{\text{SSR}}{\text{SSY}}$, $b_1 = r\dfrac{s_y}{s_x}$

Alternativa räkneformler: $\text{SSE} = \sum y^2 - b_0\sum y - b_1\sum xy$ och

$$r = \frac{\sum xy - n\bar{x}\bar{y}}{\sqrt{(\sum x^2 - n\bar{x}^2)(\sum y^2 - n\bar{y}^2)}}$$

OBS! SSE-formeln är känslig för avrundning – spara alla decimaler i b_0, b_1 (2024-10-25: 3 decimaler ger 192.948, rätt SSE = 191.702).

$s_{b_1} = \dfrac{s}{\sqrt{S_{xx}}}$, $s_{b_0} = s\sqrt{\dfrac{1}{n} + \dfrac{\bar{x}^2}{S_{xx}}}$

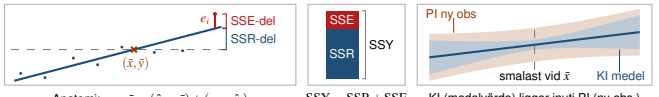
Test H_0: $\beta_1 = \beta_{10}$: $t = \dfrac{b_1 - \beta_{10}}{s_{b_1}} \sim t_{n-2}$; KI: $b_1 \pm t_{n-2;1-\alpha/2}\, s_{b_1}$

H_0: $\rho = 0$: $t = \dfrac{r\sqrt{n-2}}{\sqrt{1-r^2}}$ (samma t); $F = t^2$ (F-test $\equiv$ tvåsidigt t-test)

KI för medelvärdet $\mu_{Y|x_0}$: $\hat{y}_0 \pm t_{n-2;1-\alpha/2}\, s\sqrt{\dfrac{1}{n} + \dfrac{(x_0-\bar{x})^2}{S_{xx}}}$

PI för en ny obs. Y_0: $\hat{y}_0 \pm t_{n-2;1-\alpha/2}\, s\sqrt{1 + \dfrac{1}{n} + \dfrac{(x_0-\bar{x})^2}{S_{xx}}}$

Smalast vid $x_0 = \bar{x}$; PI alltid bredare än KI (vilket som efterfrågas: §2). Hävstång: $h_i = \frac{1}{n} + \frac{(x_i-\bar{x})^2}{S_{xx}}$. *Tips:* räkna i tabell med kolumnerna x, y, x^2, y^2, xy, $\hat{y}$, e, e^2.



Anatomi: $y_i - \bar{y} = (\hat{y}_i - \bar{y}) + (y_i - \hat{y}_i)$ heldragen linje = $\hat{y}$, streckad = $\bar{y}$ | SSY = SSR + SSE, R^2 = SSR/SSY | KI (medelvärde) ligger inuti PI (ny obs.)

7 Räknarknep och svarsbladet

- **Grafräknaren** (LinReg, 2-Var Stats) ger $a = b_0$, $b = b_1$, r, $\bar{x}$,$\bar{y}$ och standardavvikelserna – ta Sx ($n-1$ i nämnaren), inte σ_x (n; med σ_x: $S_{xx} = n\sigma_x^2$). Då: $S_{xx} = (n-1)s_x^2$, $S_{yy} = (n-1)s_y^2$, $S_{xy} = b_1 S_{xx}$, $\text{SSR} = r^2 S_{yy}$, $\text{SSE} = (1-r^2)S_{yy}$, $\text{MSE} = \text{SSE}/(n-2)$, $s_{b_1} = s/\sqrt{S_{xx}}$.
- Skriv ändå upp formel + insatta värden på papperet (poäng för redovisning); räknaren är bara kontroll.
- Spara alla decimaler i räknarens minne; avrunda **först i slutsvaret** (svarsbladet: 3 decimaler, t.ex. 24.602). Avrundade mellanled kan ändra tredje decimalen.
- Kontroller: $\sum e_i = 0$; $\text{SSR} + \text{SSE} = \text{SSY}$; $F = t^2$; $0 \le R^2 \le 1$; $\hat{y}$ vid $\bar{x}$ är $\bar{y}$. Tolkningsmening + enhet alltid med (”kr/år per m²”).

8 Genomräknat exempel – tenta 2025-10-23, uppg. 1 ($n = 6$)

x = boendeyta (m²), y = elkostnad (kr/år).

i	1	2	3	4	5	6	
x	207	168	165	99	176	139	$\sum = 954$
y	23546	20149	18971	12948	21532	14190	$\sum = 111\,336$
$\hat{y}$	23783.3	19536.1	19209.4	12021.8	20407.4	16377.9	
e	−237.3	612.9	−238.4	926.2	1124.6	−2187.9	$\sum = 0$
h_i	0.51	0.18	0.17	**0.70**	0.21	0.23	$\sum = p = 2$

$\sum x^2 = 158\,396$, $\sum y^2 = 2\,152\,928\,986$, $\sum xy = 18\,433\,163$, $\bar{x} = 159$, $\bar{y} = 18\,556$.
$S_{xx} = 158\,396 - 954^2/6 = 6710$; $S_{yy} = 86\,978\,170$; $S_{xy} = 18\,433\,163 - 954 \cdot 111\,336/6 = 730\,739$.

a) Spridningsdiagram boendeyta (x) mot elkostnad (y): starkt, positivt, linjärt samband.

b) $b_1 = 730\,739/6710 = 108.903$; $b_0 = 18\,556 - 108.90298 \cdot 159 = 1240.426$ $\Rightarrow \hat{y} = 1240.426 + 108.903x$. *Tolkning:* varje extra m² ger i genomsnitt ca 109 kr/år högre elkostnad. b_0 tolkas ej ($x = 0$ ligger utanför data). $\text{SSR} = b_1 S_{xy} = 79\,579\,655$, $\text{SSE} = 7\,398\,515$, $\text{MSE} = \text{SSE}/4 = 1\,849\,629$, $s = 1360.0$, $R^2 = 0.915$ ($r = 0.957$): 91.5 % av variationen i elkostnad förklaras av boendeytan.

c) Antagandena och hur de kontrolleras: §3.

d) e mot $\hat{y}$: inget tydligt mönster, men $n = 6$ gör bedömningen osäker. QQ-plot: normalkvantilerna $\pm 0.21, \pm 0.67, \pm 1.38$ (tabell §34) mot sorterade e. Obs. 6 ($e = -2188$, $e/s = -1.61$, jackknife -3.9) avviker; $|\text{DFFITS}| = 2.12 > 1$ (eget värde), Cook $0.49 < 1$. Obs. 4 ($x = 99$): $h = 0.70 > 2p/n = 0.67$, DFFITS $2.13 > 1$, Cook $1.85 > 1$ ⇒ inflytelserik.

§8 forts. *d) Slutsats:* linjäritet/lika varians: inget mönster, osäkert ($n=6$); normalfördelning: QQ ≈ linjen utom obs. 6; oberoende: rimligt (slumpmässigt urval).
e) H_0: $\beta_1 \le 0$ (=0) mot H_a: $\beta_1 > 0$, $\alpha = 0.10$. $s_{b_1} = 1360.0/\sqrt{6710} = 16.603$; $t = 108.903/16.603 = 6.559 > t_{4;0.90} = 1.533 \Rightarrow$ förkasta H_0: boendeyta har en positiv effekt på elkostnaden ($p \approx 0.0014$).
f)

Källa	df	SS	MS	F
Regression	1	79 579 655	79 579 655	43.025
Residual	4	7 398 515	1 849 629	
Total	5	86 978 170		

H_0: $\beta_1 = 0$ mot H_a: $\beta_1 \neq 0$; $F = 43.025 > F_{1,4;0.95} = 7.71 \Rightarrow$ förkasta H_0: modellen är signifikant ($F = t^2 = 6.559^2$).
g) $x_0 = 150$: $\hat{y}_0 = 1240.426 + 108.90298 \cdot 150 = 17575.873$

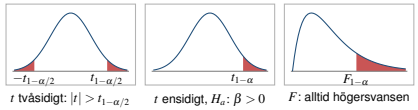
$s_{\hat{y}_0} = 1360.011\sqrt{\frac{1}{6} + \frac{(150-159)^2}{6710}} = 574.978$; $t_{4;0.975} = 2.776445$
95 % KI: $17575.873 \pm 2.776445 \cdot 574.978 = [15979.479;\ 19172.267]$ kr/år (PI för en enskild villa: [13 476.287; 21 675.460]). *Med 95 % konfidens täcker intervallet den genomsnittliga elkostnaden för villor på 150 m².*
Kontrollera din räknarteknik (tidigare tentor): 2024-10-25 uppg. 2 ($n=11$, maskiner x, minuter y): $\sum x = 43$, $\sum y = 1184$, $\sum x^2 = 201$, $\sum y^2 = 147552$, $\sum xy = 5438 \Rightarrow S_{xx} = 32.9091$, $S_{xy} = 809.6364$, $b_1 = 24.602$, $b_0 = 11.464$, $\hat{y}(4) = 109.873$, SSE = 191.7017, $s^2 = \text{SSE}/9 = 21.300$. 2025-02-28 uppg. 3 ($n=12$, näbblängd $x \to$ näbbredd y): $\sum x = 573.3$, $\sum y = 197.8$, $\sum x^2 = 27468.73$, $\sum y^2 = 3290.76$, $\sum xy = 9466.36 \Rightarrow S_{xx} = 79.3225$, $S_{xy} = 16.465$, $b_1 = 0.208$, $b_0 = 6.567$. **Extra övning – muskelmassa** ($n=60$, x = ålder): $b_1 = -1.190$ (muskelmassan minskar i genomsnitt 1.19 enheter per år), $b_0 = 156.35$; $t_{58;0.975} = 2.002$; 95 % KI för β_1: $-1.190 \pm 2.002 \cdot 0.0902 = [-1.371;\ -1.009]$; PI vid $x = 65$: $\hat{y} = 156.35 - 1.190 \cdot 65 = 79.0$, $79.0 \pm 2.002 \cdot 8.24 = [62.5;\ 95.5]$.

9 Teori: minsta kvadratskattningarnas egenskaper

Normalekvationer ($\partial\text{SSE}/\partial b_0 = \partial\text{SSE}/\partial b_1 = 0$): $nb_0 + b_1\sum x_i = \sum y_i$ och $b_0\sum x_i + b_1\sum x_i^2 = \sum x_i y_i$; i matrisform $\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}$. **Residualerna:** $\sum e_i = 0$, $\sum x_i e_i = 0$, $\sum \hat{y}_i e_i = 0$, medelvärdet av $\hat{y}_i$ är $\bar{y}$. **Väntevärdesriktiga:** $E(b_j) = \beta_j$, $E(\text{MSE}) = \sigma^2$. Gauss–Markov: OLS har minst varians bland linjära väntevärdesriktiga skattningar (BLUE) under oberoende, $E(E_i) = 0$ och lika varians; normalfördelningen behövs för t-/F-test och intervall. **Enkel regression:** $\text{Var}(b_1) = \frac{\sigma^2}{S_{xx}}$, $\text{Var}(b_0) = \sigma^2\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)$, $\text{Cov}(b_0, b_1) = -\frac{\bar{x}\sigma^2}{S_{xx}}$. Större spridning i x (större S_{xx}) ⇒ säkrare b_1. **Multipel korrelation:** $R = \text{corr}(Y, \hat{Y})$ och R^2 är dess kvadrat.

10 Hypotesprövning – skriv ut alla steg

1. Hypoteser, t.ex. H_0: $\beta_j = 0$ mot H_a: $\beta_j \neq 0$ (> 0/< 0 om ensidigt) – även i ord.
2. Signifikansnivå α (anges i uppgiften, annars 0.05).
3. Testvariabel och dess fördelning under H_0: $t = \frac{b_j - 0}{s_{b_j}} \sim t_{n-p}$, $F \sim F_{df_1, df_2}$.
4. Beslutsregel: förkasta H_0 om $|t| > t_{n-p;1-\alpha/2}$ (tvåsidigt), $t > t_{n-p;1-\alpha}$ (H_a: $>$), $t < -t_{n-p;1-\alpha}$ (H_a: $<$), $F > F_{df_1,df_2;1-\alpha}$ (alltid ensidigt) – eller om p-värdet $< \alpha$.
5. Beräkna (visa insatta värden).
6. Beslut: förkasta / förkasta inte H_0.
7. Slutsats i ord i sammanhanget: ”På 5 % signifikansnivå finns stöd för att … har ett (positivt) samband med …”. Säg aldrig att H_0 är bevisad eller sann.



t tvåsidigt: $|t| > t_{1-\alpha/2}$ | t ensidigt, H_a: $\beta > 0$ | F: alltid högersvansen
Förkasta H_0 om testvärdet hamnar i det färgade området (total area = α).

p-värde = P(minst lika extrem testvariabel | H_0 sann) – *inte* $P(H_0$ sann). Tvåsidigt $p = 2P(T > |t|)$; utskriftens `Pr(>|t|)` är tvåsidigt ⇒ ensidigt $p/2$ om b_j har tecknet i H_a. Typ I-fel: förkasta sann H_0 (risk α); typ II-fel: behålla falsk H_0. $0 \notin$ 95 %-KI ⇔ förkasta H_0: $\beta_j = 0$ på 5 % (tvåsidigt). **Enkelt:** *hur ovanligt vårt resultat vore om H_0 vore sann. Litet p ($< \alpha$) ⇒ resultatet passar dåligt med H_0 ⇒ förkasta.* **Enkelt:** *”positiv effekt” ⇒ H_a: $\beta_1 > 0$ ⇒ hela α i högra svansen ⇒ $t_{df;1-\alpha}$ (inte $1-\alpha/2$).*

11 Tolkningsmallar

- **Kvantitativ b_j:** ”När X_j ökar med en enhet förändras Y i genomsnitt med b_j enheter, givet att övriga variabler hålls konstanta.”
- **Indikator b_j:** ”Kategori A har i genomsnitt b_j enheter högre (lägre) Y än referenskategorin, givet …” – *inte* ”ökar med en enhet”.
- **Intercept b_0:** förväntat Y då alla $X = 0$; tolka bara om $X = 0$ finns i datas värdemängd. Behålls alltid i modellen.
- **R^2:** ”$100R^2$ % av variationen i Y förklaras av modellen.”
- **KI för β_j:** ”Med 95 % konfidens täcker intervallet den sanna genomsnittliga förändringen i Y när X_j ökar en enhet, givet att övriga variabler hålls konstanta.”
- **$\ln Y$ som respons:** X_j ökar en enhet ⇒ Y ändras ca $100(e^{b_j} - 1)$ % ($\approx 100\,b_j$ % om $|b_j|$ litet).
- **Interaktion/polynom:** effekten av X beror på annan variabel resp. på X – summera alla termer som innehåller X (§21, §22).

12 Multipel regression i matrisform

$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$; designmatrisen $\mathbf{X}$ ($n \times p$): första kolumnen ettor (intercept), sedan en kolumn per förklarande variabel (varje indikator räknas).

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}, \qquad \hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{H}\mathbf{Y}, \qquad \mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$$

$\mathbf{e} = \mathbf{Y} - \hat{\mathbf{Y}} = (\mathbf{I} - \mathbf{H})\mathbf{Y}$; $\text{SSE} = \mathbf{e}'\mathbf{e} = (\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{Y}'\mathbf{Y} - \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{Y}$
$\text{SSY} = \mathbf{Y}'\mathbf{Y} - \frac{1}{n}\mathbf{Y}'\mathbf{J}\mathbf{Y}$ ($\mathbf{J} = n \times n$ ettor); $\text{SSR} = \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{Y} - \frac{1}{n}\mathbf{Y}'\mathbf{J}\mathbf{Y}$
$\text{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$, skattas med $s^2(\hat{\boldsymbol{\beta}}) = \text{MSE}\,(\mathbf{X}'\mathbf{X})^{-1}$:
s_{b_j} = roten ur diagonalelement j; kovarianserna står utanför diagonalen.
Enkel regression: $\mathbf{X}'\mathbf{X} = \begin{bmatrix} n & \sum x \\ \sum x & \sum x^2 \end{bmatrix}$, $\mathbf{X}'\mathbf{Y} = \begin{bmatrix} \sum y \\ \sum xy \end{bmatrix}$, $(\mathbf{X}'\mathbf{X})^{-1} = \frac{1}{nS_{xx}}\begin{bmatrix} \sum x^2 & -\sum x \\ -\sum x & n \end{bmatrix}$.

13 ANOVA-tabell och utskrifter i tentan

Källa	df	SS	MS	F
Regression	k	$\text{SSR} = \sum(\hat{y}_i - \bar{y})^2$	$\text{MSR} = \text{SSR}/k$	MSR/MSE
Residual	$n-k-1$	$\text{SSE} = \sum(y_i - \hat{y}_i)^2$	$\text{MSE} = \text{SSE}/(n-k-1)$	
Total	$n-1$	$\text{SSY}\,(=\text{SST}) = \sum(y_i - \bar{y})^2$		

SSY = SSR + SSE (även df adderas): total = förklarad + oförklarad variation. **Enkelt:** *dela upp Y:s totala variation i ”förklarad av modellen” + ”rest”; likaså df.* ANOVA-tabellen som ges i tentan visar **sekventiella** (typ I) SS: rad 1 = $\text{SS}(X_1)$, rad 2 = $\text{SS}(X_2|X_1)$, rad 3 = $\text{SS}(X_3|X_1, X_2)$, …; en kvalitativ variabel med c kategorier = en rad med $df = c - 1$. **Enkelt:** $\text{SS}(X_2|X_1)$ = *den extra förklaring X_2 ger utöver det X_1 redan förklarat; mycket mindre än $\text{SS}(X_2)$ ⇒ de förklarar samma sak.*

- `Df`, `Sum Sq`, `Mean Sq`, `F value`, `Pr(>F)` = df, SS, MS, F, p; raden `Residuals` = SSE, MSE; SSR = summan av variabelraderna; SSY = summan av *alla* rader.
- Radens $F = \text{MS}_{\text{rad}}/\text{MSE}$ = partiellt F-test för variabeln givet raderna *ovanför*. Ordningen påverkar raderna men inte SSE, SSR, SSY.

Koefficienttabellen (ges färdig på papper – du läser av, inget körs i dator):

`Estimate`	b_j	`Residual standard error`	$s = \sqrt{\text{MSE}}$ ($n-p$ df)
`Std. Error`	s_{b_j}	`Multiple R-squared`	R^2
`t value`	$t = b_j/s_{b_j}$	`Adjusted R-squared`	R^2_a
`Pr(>|t|)`	tvåsidigt p	`F-statistic`	modell-F (k, $n-p$ df)

Baklänges: $s_b = b/t$; $\text{SSE} = s^2(n-p)$; $R^2 = 1 - \text{SSE}/\text{SSY}$; $F = \frac{R^2/k}{(1-R^2)/(n-p)}$; $\text{SSY} = \text{SSE}/(1-R^2)$.
Ex. R^2 ur ANOVA-tabellen: 0.585 (2024-10), 0.764 (2025-01), 0.915 (2025-02).

14 F-test för hela modellen

H_0: $\beta_1 = \beta_2 = \cdots = \beta_k = 0$ mot H_a: minst ett $\beta_j \neq 0$.

$$F = \frac{\text{SSR}/k}{\text{SSE}/(n-k-1)} = \frac{\text{MSR}}{\text{MSE}} \sim F_{k,n-k-1}; \quad \text{förkasta om } F > F_{k,n-k-1;1-\alpha}$$

Förkastas H_0: minst en variabel har samband med Y – modellen är bättre än att bara använda $\bar{y}$ (säger inte *vilka*). Ej signifikant ⇒ ingen idé att tolka vidare. **Enkelt:** *förklarar modellen mer än slumpen skulle göra? Förklarad variation per df delat med oförklarad per df.*

15 Partiellt F-test – grupp av s parametrar

H_0: de s testade $\beta = 0$ (t.ex. $\beta_3 = \beta_4 = \beta_5 = 0$) mot H_a: minst ett $\neq 0$. Komplett modell (F, k variabler) och reducerad modell (R, utan de s termerna, dvs. H_0 sann):

$$F = \frac{(\text{SSE}_R - \text{SSE}_F)/s}{\text{SSE}_F/(n-k-1)} = \frac{(\text{SSR}_F - \text{SSR}_R)/s}{\text{MSE}_F} = \frac{(R_F^2 - R_R^2)/s}{(1-R_F^2)/(n-k-1)} \sim F_{s,n-k-1}$$

$s = df_{E,R} - df_{E,F}$; nämnarens df = residual-df i den *kompletta* modellen. **Enkelt:** *blir modellen märkbart sämre (större SSE) utan just de här termerna? Nej ⇒ ta bort dem, ja ⇒ behåll.*
Sekventiellt: $\text{SS}(X^*|X_1, \ldots, X_k) = \text{SSE}_{X_1..X_k} - \text{SSE}_{X_1..X_k,X^*} = \text{SSR}_{X_1..X_k,X^*} - \text{SSR}_{X_1..X_k} \ge 0$. Täljaren = SS(testade | övriga) = summan av de testade variablernas rader om de står *sist* i ANOVA-tabellen. Flera variabler ⇒ använd inte radernas p-värden. $\text{SSR} = \text{SS}(X_1) + \text{SS}(X_2|X_1) + \text{SS}(X_3|X_1, X_2) + \ldots$ (inte $\text{SS}(X_1) + \text{SS}(X_2) + \ldots$ om X:en är korrelerade).
Används för: kvalitativ variabel (alla $c-1$ indikatorer), interaktions-/polynomtermer, ”kan modell A reduceras till den nästlade modellen B?”. En enda variabel sist: partiellt $F = t^2$.
Specifika värden, t.ex. H_0: $\beta_2 = 4$, $\beta_5 = -2$: reducerad modell $Y^* = Y - 4X_2 + 2X_5 = \beta_0 + \beta_1 X_1 + \beta_3 X_3 + \beta_4 X_4 + E$.
Ex. (2024-10-25) Modell 3 (SSE = 83.5003, $df = 100$) mot modell 2 (SSE = 97.4415, $df = 108$): $s = 8$, $F = \frac{(97.4415 - 83.5003)/8}{0.8350} = 2.087 > F_{8,100;0.95} = 2.03 \Rightarrow$ förkasta H_0: kan *inte* reduceras ($p = 0.044$).
Ex. (2025-02-28) $s = 6$: $F = \frac{(38803.465 - 38136.618)/6}{90.586} = 1.227 < F_{6,421;0.95} = 2.12 \Rightarrow$ förkasta inte H_0: reducera till modell 2 ($p = 0.29$).

16 t-test och KI för en parameter

H_0: $\beta_j = 0$: $t = b_j/s_{b_j} \sim t_{n-k-1}$; KI: $b_j \pm t_{n-k-1;1-\alpha/2}\,s_{b_j}$. Testar om X_j bidrar *givet att övriga variabler finns i modellen.* Tas en icke-signifikant variabel bort ⇒ anpassa om (alla b och s_b ändras) och analysera på nytt. Inte för kvalitativ variabel med flera nivåer (→ partiellt F). Ta inte bort huvudeffekter som ingår i interaktion/polynom.

17 Prediktion i multipel regression

$\mathbf{x}_0 = (1, x_{01}, \ldots, x_{0k})'$: $\hat{y}_0 = \mathbf{x}_0'\hat{\boldsymbol{\beta}}$; $s^2_{\hat{y}_0} = \mathbf{x}_0's^2(\hat{\boldsymbol{\beta}})\,\mathbf{x}_0 = \text{MSE}\,\mathbf{x}_0'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_0$.
KI för $\mu_{Y|\mathbf{x}_0}$: $\hat{y}_0 \pm t_{n-p;1-\alpha/2}\,s_{\hat{y}_0}$; PI för ny Y_0: $\hat{y}_0 \pm t_{n-p;1-\alpha/2}\sqrt{\text{MSE} + s^2_{\hat{y}_0}}$. **Ordet avgör** (§2): ”genomsnittlig” ⇒ KI även om ”en villa” nämns (2025-10-23 g). **Enkelt:** *KI = var medelvärdet för alla villor på 150 m² ligger; PI = var en enskild villa hamnar – bredare, för en enskild villa kan avvika från snittet.*
Snabbformel när tentan ger c: $c = \mathbf{x}_0'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_0$ (Kutner: $\mathbf{x}_h$) ⇒ $s^2_{\hat{y}_0} = \text{MSE} \cdot c$:

$$\text{KI: } \hat{y}_0 \pm t_{n-p;1-\alpha/2}\sqrt{\text{MSE} \cdot c} \qquad \text{PI: } \hat{y}_0 \pm t_{n-p;1-\alpha/2}\sqrt{\text{MSE}\,(1+c)}$$

Enkel regression: $c = \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}$ (= hävstången h för x_0). $c > \max h_{ii} \Rightarrow \mathbf{x}_0$ ligger utanför datamolnet (dold extrapolation). **Enkelt:** *c mäter hur långt $\mathbf{x}_0$ ligger från datas mitt – större c ⇒ bredare KI och PI.*
Ex. (sjukhusuppgiften) $\hat{y}_h = 15892$, $c = 0.93$: PI $= 15892 \pm 1183 = [14709;\ 17075]$. Sjukhusets observerade 17207 ligger *utanför* ⇒ ovanligt högt för ett sjukhus med dessa x-värden ⇒ sjukhuset ifrågasätts.
Prediktera bara inom definitionsmängden (observerade X-värden) – kontrollera min/max! Centrerade/transformerade X: transformera $\mathbf{x}_0$ på samma sätt.

18 Simultan inferens (familjekonfidens)

g oberoende test på nivå α: $P(\ge 1 \text{ typ I-fel}) = 1 - (1-\alpha)^g$ (t.ex. $g = 20$: 0.64).

- **Bonferroni:** α/g per test/intervall, $B = t_{n-p;1-\alpha/(2g)}$: $b_j \pm B s_{b_j}$; $\hat{y}_0 \pm B s_{\hat{y}_0}$ (KI); $\hat{y}_0 \pm B s_{\text{pred}}$ (PI). Bra när g är litet; bredare ju större g. **Enkelt:** *fler intervall ⇒ större risk att något blir fel ⇒ dela α mellan dem så att alla gäller samtidigt.*
- **Working–Hotelling** (konfidensband för hela linjen, godtyckligt många $\mathbf{x}_0$): $\hat{y}_0 \pm W s_{\hat{y}_0}$, $W^2 = 2F_{p,n-p;1-\alpha}$ (kurssidan; enkel regression: $W^2 = 2F_{2,n-2;1-\alpha}$). Beror inte på g.

• **§18 forts. Scheffé** (g prediktionsintervall): $\hat{y}_0 \pm S s_{\text{pred}}$, $S^2 = g\,F_{g,n-p;1-\alpha}$ (kurssidan: $S = gF$, troligen tryckfel för S^2 – ange din formel), $s_{\text{pred}} = \sqrt{\text{MSE} + s^2_{\hat{y}_0}}$.

Välj metoden med minst multiplikator (B mot W, resp. B mot S).

19 Förklaringsgrad

$R^2 = \frac{\text{SSR}}{\text{SSY}} = 1 - \frac{\text{SSE}}{\text{SSY}} \in [0,1]$: andel förklarad variation. Ökar (minskar aldrig) när variabler läggs till – straffar *inte* komplexitet ⇒ jämför inte modeller av olika storlek med R^2. **Enkelt:** *hur stor del av Y:s "gungande" som linjen förklarar – $R^2 = 0.91$ betyder att 91 % förklaras, 9 % är kvar som rest.*

$R^2_a = 1 - \frac{\text{SSE}/(n-k-1)}{\text{SSY}/(n-1)} = 1 - (1-R^2)\frac{n-1}{n-k-1}$: straffar antalet variabler; högre = bättre; kan minska. Enkel regression: $R^2 = r^2$. **Enkelt:** *R^2 med straff för varje extra variabel – belönar bara variabler som faktiskt hjälper.*

20 Indikatorvariabler (dummyvariabler)

Kvalitativ variabel med c kategorier ⇒ $c-1$ indikatorer (0/1); utelämnad kategori = **referenskategori**. Alla c + intercept ⇒ perfekt samband, $\mathbf{X'X}$ singulär. b_j = genomsnittlig skillnad i Y mot referensen, givet övriga konstanta (parallellförskjuten linje: annat intercept, samma lutning). Hela variabeln testas med partiellt F (H_0: alla $c-1$ $\beta = 0$). **Enkelt:** *en på/av-knapp (1/0) som flyttar hela linjen upp eller ner för en grupp; referensgruppen har knappen av.* I koefficienttabellen: `region2`, `affiliation2` = indikator för nivå 2 jämfört med referensnivån 1.

Ex. (2025-02-28) `geographic_region2`, $b = 5.0046$: "Kommuner i Mellanvästern har i genomsnitt ca 5 tusen fler anmälda allvarliga brott än kommuner i Nordost (referens), givet att övriga variabler hålls konstanta."

21 Interaktioner

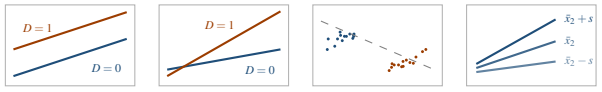
Kvalitativ × kvantitativ: $Y = \beta_0 + \beta_1 X + \beta_2 D + \beta_3 XD + E$, $D \in \{0,1\}$:
$D=0$: $Y = \beta_0 + \beta_1 X$; $D=1$: $Y = (\beta_0+\beta_2) + (\beta_1+\beta_3)X$.
β_2 = skillnad i intercept, β_3 = skillnad i lutning (effekten av X skiljer sig mellan grupperna). t-test av β_3: lika lutningar? Partiellt F för $\beta_2 = \beta_3 = 0$: identiska linjer? Fler kategorier ⇒ en interaktion per indikator. **Enkelt:** *effekten av X är olika beroende på en annan variabel – t.ex. brantare elkostnadslinje för eluppvärmda hus.*

Ex. (2025-10-23, mod_4):
$\hat{y} = 3604.88 + 113.54\,\text{Boyta} + 1857.10\,\text{El} + 76.15\,\text{Boyta}\cdot\text{El}$ ⇒ ej eluppvärmd: $\hat{y} = 3604.88 + 113.54x$; eluppvärmd: $\hat{y} = 5461.98 + 189.69x$.

Kvantitativ × kvantitativ: $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + E$: effekten av X_1 är $\beta_1 + \beta_3 X_2$ (beror på X_2) – tolka genom att fixera X_2 (t.ex. $\bar{x}_2$ och $\bar{x}_2 \pm s$) och visualisera.

Upptäck: grupperade spridningsdiagram (olika lutning per grupp), korsmönster i residualer mot X per grupp, X_1X_2 mot Y, mönster i residualdiagrammen. **Hierarki:** behåll huvudeffekterna (även om de inte är signifikanta) när interaktionen ingår.

Modellformler i tentan: $A \times B$ (eller $A * B$) = $A + B + A{:}B$; $A{:}B$ = bara produkttermen; $A \times B \times C \times D$ = alla huvudeffekter och alla interaktioner upp till fjärde ordningen ($2^4 - 1 = 15$ termer, mod_3 i tentan 2025-10-23) ⇒ överanpassning, svårtolkat, höga VIF.



Indikator: parallella linjer | Interaktion: olika lutning | Simpsons paradox | Kvant×kvant: lutningen för X_1 beror på X_2

22 Polynom och transformationer

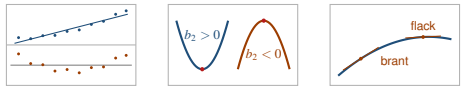
$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + E$ är fortfarande en *linjär* modell (linjär i parametrarna) ⇒ OLS. **Enkelt:** *en böjd linje – vi ger modellen X^2 som extra variabel så den får svänga.*

Kurssidans recept (modellsvar §31): krökning i diagram/residualer → skapa X^2 som ny variabel, OLS → kontrollera residualerna igen → tolka X genom alla termer ($b_1 + 2b_2x$), aldrig b_1 ensam.

Effekten av X: $\mathrm{d}\hat{y}/\mathrm{d}x = b_1 + 2b_2x$ (beror på x); $b_2 > 0$ ⇒ U-form, $b_2 < 0$ ⇒ ∩-form; extrempunkt i $x = -b_1/(2b_2)$. Behövs krökningen? t-test för β_2 (partiellt F för flera högre termer). Högre grad ($X^3, \ldots$) bara om residualerna kräver det.

Centrering $X_c = X - \bar{x}$: minskar korrelationen mellan X och X^2 (VIF) och beräkningsproblem – gör beräkningarna stabilare, inte modellen bättre. Ändrar b_0, b_1 och deras tolkning (b_1 = lutningen vid $x = \bar{x}$: förändringen i Y när X:s **avstånd från sitt medelvärde** ökar med 1), men *inte* b_2, $\hat{y}$, residualerna, SSE eller R^2. Prediktion: centrera x_0 först!

Transformera Y: $\ln Y$ eller $\sqrt{Y}$ vid högerskeva residualer/ökande varians (tratt); $\ln X$ vid avtagande effekt. För hög polynomgrad ⇒ modellen följer bruset (överanpassning).

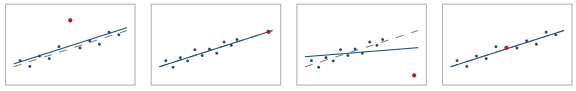


Rak linje på krökt data (övre) ⇒ banan-residualer (nedre) | U om $b_2 > 0$, ∩ om $b_2 < 0$ extrempunkt i $x = -b_1/(2b_2)$ | Lutningen $b_1 + 2b_2x$ ändras med x

23 Avvikande och inflytelserika observationer

- **Residual** $e_i = y_i - \hat{y}_i$, $\text{Var}(e_i) = \sigma^2(1-h_i)$. **Standardiserad** $z_i = e_i/s$: antal standardavvikelser från residualernas medelvärde 0. **Enkelt:** *residualen mätt i antal "vanliga residualstorlekar" (s); $|z| > 2$–3 är ovanligt stort.*
- **Studentiserad (intern)** $r_i = \dfrac{e_i}{s\sqrt{1-h_i}}$.
- **Jackknife** (externt studentiserad): residual från en modell anpassad *utan* obs. i: $r_{(-i)} = e_i\sqrt{\dfrac{n-k-2}{\text{SSE}(1-h_i) - e_i^2}} = r_i\sqrt{\dfrac{n-k-2}{n-k-1-r_i^2}} \sim t_{n-k-2}$; $|r_{(-i)}| > 2$–3 ⇒ avvikande i Y-led. **Enkelt:** *standardiserad = e/s; studentiserad tar även hänsyn till h; jackknife = som studentiserad men punkten har inte fått dra i linjen.*
- **Leverage** h_i = diagonalen i $\mathbf{H}$: $0 \le h_i \le 1$, $\sum h_i = p$, medel p/n; avvikande i X-led om $h_i > 2p/n$ (beror bara på X). **Enkelt:** *hur långt ut i x-led punkten ligger – en lång hävstång kan vrida linjen mycket.*
- **DFFITS**$_i$ $= r_{(-i)}\sqrt{\dfrac{h_i}{1-h_i}}$: inflytande på *sitt eget* anpassade värde; gräns $|\text{DFFITS}| > 1$ (små/medelstora data), $> 2\sqrt{p/n}$ (stora data).
- **Cook's** $d_i = \dfrac{1}{p}\cdot\dfrac{h_i}{1-h_i}\cdot r_i^2$: inflytande på *alla* anpassade värden; gräns $d_i > 1$, eller robust: värde ur Kleinbaum tabell A.10 (n, k, α) delat med $n-(k+1)$ (saknas A.10: använd gränsen 1 och skriv det). **Enkelt:** *ta bort punkten och anpassa om: DFFITS = hur mycket punktens egen prognos flyttar sig; Cook = hur mycket alla prognoser flyttar sig.*

Avvikande Y nära $\bar{x}$ (lågt h) flyttar linjen lite; högt h + avvikande Y ⇒ stort inflytande; högt h men på linjen ⇒ ofarlig.


Avvikande Y nära $\bar{x}$ $h\downarrow e\uparrow$ Cook↓: linjen flyttas lite | Ytterkant, på linjen $h\uparrow e\downarrow$ Cook↓: ofarlig | Ytterkant + avvikande Y $h\uparrow e\uparrow$ Cook↑: inflytelserik | Vanlig punkt $h\downarrow e\downarrow$ Cook↓
streckad = sann linje, heldragen = anpassad linje, röd = den undersökta punkten

Ex. (2024-10-25, $n = 20$ = litet): gräns 1 för båda; obs. 13: DFFITS $= -1.4$, Cook $= 0.9$ ⇒ inflytelserik endast på sitt eget anpassade värde.

Ex. (2025-02-28, $n \approx 437$, $p = 10$): DFFITS-gräns $2\sqrt{10/437} \approx 0.30$; Cook $18.43/421 \approx 0.04$ ⇒ flera inflytelserika obs.

Hantering: (1) leta mät-/inmatningsfel; (2) undersök obs.:ens X- och Y-värden – vad särskiljer den?; (3) ta bara bort med motivering (fel, annan population) och redovisa; (4) börja med den mest inflytelserika – övriga mått ändras när den tas bort, anpassa om; (5) jämför modellen med/utan.

24 Multikollinearitet

Starka samband *mellan* förklarande variabler. Följder: uppblåsta s_{b_j} ⇒ icke-signifikanta t-test trots signifikant F; instabila skattningar, "fel" tecken; $\text{SS}(X_2) \gg \text{SS}(X_2|X_1)$ (variablerna förklarar samma variation). Prediktioner och R^2 påverkas mindre.

$\text{VIF}_j = \dfrac{1}{1-R_j^2}$, R_j^2 från regression av X_j på övriga X (*utan* Y). VIF $= 5 \Leftrightarrow R_j^2 = 0.8$; VIF $= 10 \Leftrightarrow R_j^2 = 0.9$. **Enkelt:** *hur många gånger större variansen för b_j blir för att X_j går att förutsäga ur de andra X – två variabler berättar samma sak och modellen vet inte vem som ska få äran.*

Tumregler: enskilt VIF > 10 eller medel-VIF > 5 ⇒ hög risk; enskilt VIF > 5 = förhöjd risk. Parvis $|r| > 0.9$ ⇒ överhängande risk (lösningsförslag). GVIF (kvalitativ variabel): $df = 1$ ⇒ GVIF = VIF; annars jämför $\text{GVIF}^{1/(2df)}$ med $\sqrt{5} \approx 2.24$ resp. $\sqrt{10} \approx 3.16$. Polynom/interaktioner ger artificiellt höga VIF – centrera och bedöm grundvariablerna (beräkna GVIF per grundvariabel).

Ex. (2024-10-25) Antal bäddar (VIF 35.7), patienter/dag (37.8), sjuksköterskor (7.5) har $r = 0.91$–0.98 sinsemellan ⇒ multikollinearitet; modell 2 saknar dem (låg risk), modell 1 har två kvar. Lösningen räknar även sjuksköterskor (VIF $7.5 > 5$); medel-VIF modell 3 = $9.4 > 5$.

Åtgärder: ta bort en av de korrelerade variablerna, kombinera dem (kvot/index), centrera, samla mer data.

25 Studiedesign, confounding, Simpsons paradox

Observationsstudie: vi observerar bara ⇒ endast korrelationssamband, inga kausala slutsatser. **Experiment:** forskaren styr X (randomisering, kontroll) ⇒ kausala slutsatser möjliga. Korrelation ≠ kausalitet (filmer med Nicolas Cage mot drunkningar).

Confounder (störfaktor): variabel som påverkar både X och Y ⇒ skenbart/förvrängt samband. **Enkelt:** *en tredje sak som påverkar både X och Y och lurar oss att tro att X orsakar Y (glassförsäljning och drunkningar: sommaren).* **Kontrollvariabel**: tas med i modellen för att justera (isolera) effekten av variabeln av intresse (t.ex. ålder och kön i en medicinstudie).

Simpsons paradox (definition och modellsvar §31): **Enkelt:** *inom varje grupp går sambandet åt ett håll, men blandar man grupperna ser det ut att gå åt andra hållet.* Upptäck: färglägg spridnings-/residualdiagram efter grupp. Åtgärd: inkludera grupperingsvariabeln (ev. interaktion).

Ex. (2025-02-28, uppg. 3) e mot $\hat{y}$ markerat per art: Chinstrap har positiva residualer (underskattas), Gentoo negativa (överskattas) ⇒ art påverkar sambandet och bör ingå i modellen.

26 Modellval och validering

Mått	Bäst
R^2	högt – men ökar alltid (ej olika storlek)
R^2_a	högt
$s = \sqrt{\text{MSE}}$	lågt
Mallows $C_p = \dfrac{\text{SSE}_p}{\text{MSE}_{\text{full}}} - (n-2p)$	$C_p \approx p$ och litet (fulla modellen har alltid $C_p = p$)
$\text{AIC} = n\ln(\text{SSE}/n) + 2(p+1)$	lågt; straffar komplexitet (generaliserbarhet)
$\text{AICc} = \text{AIC} + \dfrac{2(k+1)(k+2)}{n-k-2}$	lågt; när n är litet (→ AIC när n växer)
$\text{PRESS} = \sum\left(e_i/(1-h_{ii})\right)^2$	lågt = bra prediktionsförmåga; ≥ SSE
$\text{MSPR} = \frac{1}{n^*}\sum(y_i^* - \hat{y}_i^*)^2$	lågt (valideringsdata); ≫ MSE ⇒ överanpassad
K-faldig CV $= \frac{1}{K}\sum_{k=1}^{K}\text{MSE}_k$	lågt; $K = n$ (LOOCV) ⇒ PRESS/n

(p = alla parametrar i delmodellen inkl. intercept och varje indikator; 2025-01: 9 var. men fulla modellens $C_p = 16 = p$.) **Intern** validering: mått på träningsdata (R^2_a, AIC, C_p, PRESS). **Extern**: dela data slumpmässigt i träning (≥ 50 %) och validering (≥ 10 %) och jämför MSPR; testmängd ger väntevärdesriktig skattning för den slutliga modellen; K-faldig korsvalidering: K delar turas om att vara valideringsdel (MSE_k; tränas på övriga $K-1$). Tidsserier: dela vid en tidpunkt. **Enkelt:** *C_p jämför delmodellens fel med fulla modellens; $C_p \gg p$ ⇒ viktig variabel saknas, $C_p \approx p$ ⇒ lagom.* **Enkelt:** *AIC = hur dåligt modellen passar (SSE) + straff per parameter; lägst vinner – säger något om hur den klarar ny data.*

§26 forts. Enkelt: *MSPR = modellens genomsnittliga kvadratfel på data den inte sett; MSPR ≫ MSE ⇒ den har lärt sig bruset.* **Enkelt:** *PRESS = varje punkt predikteras av modellen anpassad* utan *den* $(e_i/(1-h_{ii}))$*; nära SSE ⇒ generaliserar bra.* **Underanpassning**: för enkel, missar samband. **Överanpassning**: för komplex, modellerar bruset, generaliserar dåligt.



MSE sjunker alltid – MSPR (validering) vänder uppåt vid överanpassning

Algoritmer – för- och nackdelar

	✓ Fördel	✗ Nackdel
Best subsets	alla 2^k-1 modeller ⇒ missar ingen; visar bästa per storlek	tung när k är stort; olika mått kan peka på olika modeller
Framåtval (tom +)	snabb; går även när fulla modellen är för stor att anpassa	en tillagd variabel tas aldrig bort
Bakåtelim. (full −)	bedömer varje variabel givet alla andra	fulla modellen måste kunna anpassas; borttagen kommer ej tillbaka
Stegvis (±)	kan ångra tidigare steg	fortfarande girig – ingen garanti för bästa modellen

Stegvisa algoritmer är *giriga* (ser ett steg i taget), känsliga för multikollinearitet och kan välja interaktion utan huvudeffekter. Bästa måttvärde ≠ lämplig modell ⇒ alltid residualanalys och test efteråt. Kvalitativa variabler hanteras som en grupp.
Ex. (2025-01-20) Största modellen (9 var.) bäst på R^2 och R^2_a; modell 8 bäst på C_p och AIC (straffar komplexitet ⇒ mer tillförlitliga för generaliserbarhet). Boyta–antal rum $r = 0.815 < 0.9$ ⇒ ingen överhängande multikollinearitetsrisk.

27 Välj modell – checklista och ex. 2025-10-23, uppg. 2

(1) **Lämplighet:** residualdiagram (mönster, varians, normalitet, extremvärden). (2) **Anpassning mot komplexitet:** R^2_a, AIC, C_p, s – välj den enklaste modell som förklarar i stort sett lika bra. (3) **Test:** F för modellen, partiellt F mellan nästlade modeller, t för termerna. (4) **Multikollinearitet:** korrelationsmatris, VIF. (5) **Tolkningsbarhet** och hierarki. (6) **Prediktion** inom definitionsmängden.

Modell	k	R^2_a	Bedömning
mod_1	5	0.918	5 huvudeffekter: krökt e mot $\hat{y}$ (saknar interaktion); Tomtyta–Boendeyta $r = 0.93$; Takhöjd och Tomtyta ej signifikanta
mod_2	3	0.418	utan Eluppvärmt: två grupper i e, S-formad QQ ⇒ viktig variabel saknas (Eluppvärmt, $r = 0.74$ med Y)
mod_3	15	0.945	alla interaktioner upp till 4:e ordningen: bra residualer men överanpassad och svårtolkad
mod_4	3	0.941	Boendeyta × Eluppvärmt: slumpmässig svärm, rak QQ ⇒ **välj**

Partiellt F (mod_4 är nästlad i mod_3): $F = \frac{(624\,728\,614 - 507\,449\,855)/12}{507\,449\,855/84} = 1.62 < F_{12,84;0.95} = 1.87$ ⇒ extratermerna behövs inte. Modell-F för mod_4: $\frac{10\,260\,304\,836/3}{624\,728\,614/96} = 525.6 > F_{3,96;0.95} = 2.70$. Interaktion $t = 6.46 > t_{96;0.975} = 1.985$ ⇒ effekten av boendeyta är större för eluppvärmda (189.7 mot 113.5 kr/m^2); Eluppvärmt ($t = 0.87$) behålls (hierarki). Prediktion (eluppvärmd, 200 m^2): $3604.88 + 113.54 \cdot 200 + 1857.10 + 76.15 \cdot 200 = 43\,399.980$ kr/år. Antal rum, takhöjd och tomtyta ingår inte i mod_4 (tomtyta 1700 > max 1523 hade dessutom varit extrapolering).

28 Utvärdera en modell – ”Är modellen bra och lämplig?”

Lämplig = antagandena i §3 uppfyllda – skriv *vad du ser* och *vad det betyder*; extremvärden/inflytelserika observationer (DFFITS, Cook) – nämn dem och föreslå undersökning. **Bra** = högt R^2/R^2_a (ange siffran), signifikant F-test, rimliga och signifikanta koefficienter, ingen allvarlig multikollinearitet, lagom komplex. Avsluta med en samlad bedömning + förbättringsförslag (transformera Y, lägg till variabel/interaktion, undersök extremvärden).
Ex. (2025-02-28, 1d) ”Förklaringsgraden är hög (≈ 0.91) och modellen är signifikant enligt F-testet. Residualerna är ungefär normalfördelade (klockformat histogram, QQ-punkterna följer linjen) men det finns många extremvärden i båda riktningarna. Variansen ökar med större anpassade värden ⇒ lika varians är inte uppfyllt. Extremvärdena bör undersökas (DFFITS, Cook’s distance) och en transformation av Y övervägas.”

29 Sant/falskt – påståenden från tidigare tentor

Uppgiften: markera 2 korrekta resp. 2 falska påståenden; fel markering ger −1 p ⇒ markera bara det du är säker på. **S**= sant, **F**= falskt.

F F-test för modellen och partiellt F-test undersöker samma hypoteser. (Alla β resp. en delmängd.)
F Ett t-test kan avgöra om en kategorisk variabel med flera nivåer har samband med Y. (Partiellt F.)
S Kvantitativ variabel: ”när variabeln ökar en enhet förändras Y med koefficientens värde” (givet övriga konstanta).
F Kategorisk variabel tolkas som ”ökar med en enhet”. (Jämförelse mot referenskategorin.)
F Normalfördelningen kontrolleras med histogram över responsvariabeln. (Över residualerna.)
S Stark korrelation mellan förklarande variabler riskerar problem med multikollinearitet.
S En kontrollvariabel justerar effekten av de andra variablerna för att hantera confounding.
F Jackknife-residualer anger residualen i enheten ”standardavvikelser från residualernas medelvärde”. (Det gör standardiserade residualer.)
S En kvalitativ variabel modelleras med en indikatorvariabel färre än antalet kategorier.
S Polynom kan modellera icke-linjära samband i en linjär modell.
S $\mathrm{SS}(X_2|X_1)$ beskriver hur mycket variation X_2 tillför en modell som redan innehåller X_1.
F Pearsons korrelationskoefficient är alltid lämplig för att mäta styrkan i ett samband. (Bara linjära.)
F Förklaringsgraden R^2 straffar modellen för antalet variabler. (Det gör R^2_a.)
S Den justerade förklaringsgraden straffar måttet utifrån antalet variabler i modellen.
F En låg justerad förklaringsgrad visar på en bättre modell.
S Cook’s distance visar om en observation har inflytande på alla anpassade värden.
S DFFITS visar om en observation har inflytande på sitt eget anpassade värde.
F Framåtval, bakåteliminering eller stegvis regression leder alltid till den bästa modellen.
S Ett lägre AIC-värde är önskvärt när modeller jämförs.
F Det enda sättet att bedöma en modells generaliserbarhet är extern validering. (T.ex. AIC.)
F I en observationsstudie med två förklarande variabler är $\mathrm{SSY} = \mathrm{SS}(X_1) + \mathrm{SS}(X_2) + \mathrm{SSE}$. (Rätt: $\mathrm{SS}(X_1) + \mathrm{SS}(X_2|X_1) + \mathrm{SSE}$.)
S I enkel linjär regression testar t-testet för lutningen samma hypoteser som F-testet för modellen ($F = t^2$).

Fler troliga påståenden:

S R^2 kan aldrig minska när en variabel läggs till.
S Sekventiella SS beror på variablernas ordning (men summerar alltid till SSR); SSE och SSR gör det inte.
F Ett icke-signifikant intercept ska tas bort ur modellen.
S Prediktionsintervallet är bredare än KI för medelvärdet vid samma x_0.
F Hög leverage innebär alltid att observationen är inflytelserik.
F p-värdet är sannolikheten att H_0 är sann.
F En observationsstudie kan påvisa kausala samband.
S Centrering minskar multikollinearitet mellan X och X^2; den ändrar b_0 och b_1 men inte b_2, $\hat{y}$ eller R^2.
F Bonferroniintervall blir smalare ju fler intervall som skattas.
S I enkel linjär regression är R^2 kvadraten på Pearsons r.
F Leverage mäter hur avvikande observationen är i Y-led. (I X-led; Y-led = jackknife/standardiserad residual.)
F Vid ensidig mothypotes används $t_{df;1-\alpha/2}$. ($t_{df;1-\alpha}$.)
S Residualerna summerar till 0 i en modell med intercept.
F Standardiserade residualer tar hänsyn till observationens leverage. (Det gör studentiserade/jackknife.)
F MSPR beräknas på träningsdata. (Valideringsdata.)
S Signifikant F-test: minst en (inte alla) lutningsparametrar är skild från 0.

30 Utblick: logistisk regression och GLM (kap. 10–11)

Binär Y: $\pi = P(Y=1|X)$, logit $\ln\frac{\pi}{1-\pi} = \mathbf{x}'\beta$; e^{b_j} = oddskvot: oddset för $Y=1$ multipliceras med e^{b_j} när X_j ökar en enhet. Ingen SSE/R^2; Wald: $z = b_j/s_{b_j}$.

31 Teorifrågor – korta modellsvar

När används polynom, och hur anpassas och tolkas de? När sambandet mellan X och Y är icke-linjärt (krökt spridningsdiagram eller krökta residualer). Polynomtermerna ($X^2, X^3, \ldots$) läggs till som separata variabler och modellen skattas med minsta kvadratmetoden (centrera gärna X). Effekten av X tolkas genom att summera alla termers bidrag ($b_1 + 2b_2 x$), inte en term i taget.
Förklara Simpsons paradox. Ett samband som syns inom flera grupper försvinner eller byter riktning när grupperna slås ihop, t.ex. positivt samband mellan näbbredd och näbblängd inom varje pingvinart men negativt totalt. Paradoxen kan dölja eller förvränga sambanden i en regressionsmodell ⇒ ta med grupperingsvariabeln.
Varför inte t-test för en kategorisk variabel med flera nivåer? Variabeln motsvaras av $c-1$ parametrar; varje t-test jämför bara en kategori med referensen (och beror på valet av referens). Hela variabeln: partiellt F (H_0: alla $c-1$ $\beta = 0$).

32 Tentatips

- Svarsbladet: numeriska svar med tre decimaler i rutorna (10.693 → 1 0 . 6 9 3); uträkningar och tolkningar på separat papper. Nytt svarsblad: **ett** kryss per flervalsfråga om inget annat anges – läs instruktionen (2+2-formatet gällde 2024–25).
- Redovisa, tolka och motivera: formel → insatta värden → resultat → mening på svenska med enhet och ”i genomsnitt / givet övriga konstanta”.
- Saknas en siffra: skriv det, anta ett rimligt värde och lös vidare. Tabellavläsning och interpolering: §34.

33 Vanliga fel att undvika

✗ Fel df: $\mathrm{MSE} = \mathrm{SSE}/(n-2)$ i enkel regression (inte $n-1$), allmänt $n-(k+1)$; i partiellt F tas nämnarens df från den *kompletta* modellen.
✗ Glömma ”i genomsnitt” och ”givet att övriga hålls konstanta” i tolkningar.
✗ Ej förkastad $H_0 \neq$ ”inget samband finns” – skriv ”inte tillräckligt stöd för …”.
✗ Kontrollera normalfördelning på Y i stället för på residualerna.
✗ t-test för kategorisk variabel med flera nivåer, eller radernas p-värden i ANOVA-tabellen för flera variabler samtidigt (⇒ partiellt F).
✗ Jämföra R^2 mellan modeller av olika storlek (⇒ R^2_a, AIC, C_p).
✗ Ta bort en huvudeffekt som ingår i en interaktion eller ett polynom.
✗ Extrapolera utanför observerade X; glömma att centrera x_0 (centrerad modell).

34 Tabellsamlingen – så läser du den

t-tabellen: rad = df, kolumn = sannolikhet q med $P(T \le t_{df;q}) = q$ (tvåsidigt test/KI: $q = 1-\alpha/2$; ensidigt: $q = 1-\alpha$). Vissa tabeller anger svanssannolikheten α – läs rubriken: $t_{df;0.975}$ = kolumn 0.975 **eller** kolumn ”$\alpha = 0.025$”. **F-tabellen:** en tabell per α; täljar-df (df_1) i kolumner, nämnar-df (df_2) i rader. **Normalfördelningen:** $z_{0.975} = 1.96$, $z_{0.95} = 1.645$.

Använda tabellerna. Saknas exakt df: ta närmast *lägre* df (konservativt) eller interpolera linjärt i $1/df$: $q \approx q_1 + (q_2 - q_1) \cdot \left(\frac{1}{df} - \frac{1}{df_1}\right)/\left(\frac{1}{df_2} - \frac{1}{df_1}\right)$; t.ex. $F_{6,421;0.95}$ ligger mellan $df_2 = 200$ (2.14) och 500 (2.12) ⇒ ≈ 2.12. Samband: $F_{1,df;1-\alpha} = t^2_{df;1-\alpha/2}$, $t_{\infty;q} = z_q$, $t_{df;\alpha} = -t_{df;1-\alpha}$.
p-värde ur tabell: se mellan vilka kolumner testvärdet hamnar, t.ex. $t = 2.5$ med $df = 20$: $2.086 < 2.5 < 2.528$ ⇒ $0.01 < p < 0.025$ ensidigt, $0.02 < p < 0.05$ tvåsidigt.

QQ-plot för hand: sorterade e_i mot normalkvantilerna $z_{(i-0.5)/n}$, $i \le \lceil n/2 \rceil$ (resten: byt tecken):

n	$i=1$	2	3	4	5	6
5	−1.28	−0.52	0.00			
6	−1.38	−0.67	−0.21			
7	−1.47	−0.79	−0.37	0.00		
8	−1.53	−0.89	−0.49	−0.16		
9	−1.59	−0.97	−0.59	−0.28	0.00	
10	−1.64	−1.04	−0.67	−0.39	−0.13	
11	−1.69	−1.10	−0.75	−0.47	−0.23	0.00
12	−1.73	−1.15	−0.81	−0.55	−0.32	−0.10